

Descubra emoções em textos com NLP, LLMs e ML

Ministrante: Bernardo de Castro Monteiro Franco Gomes



SOBRE MIM:

Graduando em Ciência da Computação - UFSJ

- Possuo 19 anos
- Dou aulas de Desenvolvimento Full-Stack e Aprendizado de Máquina
- Desenvolvo projetos, minicursos e palestras para feiras de tecnologia e para faculdade
 - Projeto: CommentSentimentAPI
 - Projeto: Orienta.IA
 - Minicurso: Desenvolvimento Prático de Sistemas com JavaScript e Flask
- Trabalho como freelancer em projetos relacionados com Aprendizado de Máquina e Jogos (Ex: Minecraft)


OBJETIVO DO TUTORIAL

1. Entender como emoções podem ser identificadas em textos
2. Aprender fundamentos de PLN, LLMs e ML
3. Construir uma pipeline prática de análise emocional
4. Explorar modelos tradicionais e modelos modernos
5. Compreender custos, limitações e boas práticas
6. Implementar um sistema funcional utilizando Python

BIBLIOTECAS QUE VAMOS UTILIZAR

PLN	ML	LLM	VISUAL
NLTK	Scikit-Learn	Transformers	Matplotlib
Spacy	Pandas	Hugging Face	Seaborn
TextBlob	NumPy		


PANORAMA PLN | O QUE É?



Área da inteligência artificial que se dedica à interpretação, compreensão e geração de linguagem humana por computadores.

Ponte entre o que os seres humanos dizem ou escrevem e a capacidade das máquinas de responder de maneira coerente e contextual.

PANORAMA PLN | COMO FUNCIONA PLN?



Combina-se conceitos da linguística e da ciência da computação para permitir que máquinas entendam a linguagem natural, ou seja, como nós humanos nos comunicamos no dia a dia.

Atualmente existe uma grande limitação no PLN...

PANORAMA PLN | PRINCIPAIS FUNÇÕES

1. Análise de Sentimentos: Identificar emoções e opiniões em textos
2. Tradução automática: Realizar traduções em tempo real
3. Reconhecimento de fala: Converter fala em texto
4. Chatbots e Assistentes Virtuais: Simulam conversas humanas
5. Geração de texto automático: Criar conteúdos baseados em comandos ou padrões

PANORAMA PLN | IMPACTO NO FUTURO


Algo que já possuímos atualmente é o PLN deixando de ser apenas uma camada da interface, inclusive já sendo considerada uma área a parte da ciência e da área do desenvolvimento - “deixando” de ser uma área de pesquisa do Aprendizado de Máquina.

Alguns pontos que iremos ver o PLN trazendo um forte impacto são:

- Educação
- Saúde e bem-estar
- Produtividade
- Serviços públicos
- Acessibilidade

PANORAMA LLM | O QUE É?

Os LLMs ou Modelos de Linguagem de Grande Porte, tem capacidade de processar, compreender e gerar textos em linguagem natural, tornando possíveis assistentes virtuais, sistemas de recomendação e chatbots que já fazem parte do nosso cotidiano.



PANORAMA LLM | COMO FUNCIONA UMA LLM?

Podemos falar que em um nível básico as LLMs são desenvolvidas com Aprendizado de Máquina. O aprendizado de máquina é um subconjunto da IA e refere-se à prática de alimentar um programa com grandes quantidades de dados para treinar o programa a identificar recursos desses dados sem intervenção humana.

LLMs utilizam o Aprendizado Profundo, eles podem essencialmente se treinar para reconhecer distinções sem intervenção humana, embora seja necessário algum ajuste fino humano.

PANORAMA LLM | PRINCIPAIS FUNÇÕES

1. Análise de sentimentos e monitoramento de marca
2. Análise de dados não estruturados
3. Criação de ferramentas de acessibilidade
4. Detecção de fraudes
5. Sistema de recomendação

PANORAMA LLM | COMO USAR LLM ABERTA

Para utilizar uma LLM aberta precisamos seguir alguns passos:

1. Escolher o modelo adequado
2. Preparar o ambiente
3. Ajustes
4. Teste e Validação
5. Integração e Produção
6. Atualizações e Manutenções



PANORAMA LLM | COMO USAR LLM ABERTA

Existem alguns conceitos importantes quando estamos trabalhando com uma LLM aberta que precisamos saber, sendo eles:

RAG (Retrieval-Augmented Generation): Ampliar a capacidade de resposta de LLMs, combinando o conhecimento interno do modelo de linguagem com sistemas de recuperação de informações.

Fine-Tuning: Processo que permite adaptar modelos de Inteligência Artificial pré-treinados para tarefas ou domínios específicos, utilizando datasets menores e direcionados.

PANORAMA ML | O QUE É A ML?

Machine Learning (ML) ou Aprendizado de Máquina é uma área da Inteligência Artificial responsável por permitir que computadores aprendam padrões a partir de dados, sem serem explicitamente programados para cada tarefa.

Ao invés de seguir apenas regras fixas, os modelos de ML conseguem identificar comportamentos, relações e tendências nos dados, realizando previsões, classificações e tomadas de decisão.

No contexto da análise emocional, o ML é utilizado para aprender como emoções aparecem em textos e classificá-las automaticamente.

PANORAMA ML | COMO FUNCIONA?

O Machine Learning funciona através do treinamento de modelos utilizando grandes quantidades de dados.


O processo geralmente segue as seguintes etapas:

1. Coleta de dados
2. Pré-processamento
3. Transformação dos dados em vetores numéricos
4. Treinamento do modelo
5. Avaliação de desempenho
6. Predição de novos dados

PANORAMA ML | PRINCIPAIS FUNÇÕES

1. Classificação de dados
2. Reconhecimento de padrões
3. Sistemas de recomendação
4. Previsões e análises
5. Detecção de fraudes
6. Automação inteligente

PANORAMA ML | TIPOS DE APRENDIZADO



RELAÇÃO PLN X LLM X ML

O Machine Learning (ML) é uma grande área da Inteligência Artificial responsável por criar modelos capazes de aprender com dados.

O Processamento de Linguagem Natural (PLN/NLP) é uma área que utiliza técnicas computacionais para permitir que máquinas entendam a linguagem humana.

Já os LLMs (Large Language Models) são modelos avançados de Machine Learning treinados em enormes volumes de texto utilizando Deep Learning.

Enquanto o PLN tradicional trabalha com técnicas estruturadas e estatísticas, os LLMs conseguem compreender contexto, nuances, intenções e emoções de forma muito mais avançada.

IMPORTÂNCIA DA ANÁLISE EMOCIONAL

Com o crescimento das redes sociais e plataformas digitais, milhões de opiniões e emoções são compartilhadas diariamente.

A análise emocional permite identificar automaticamente sentimentos, emoções e intenções presentes em textos, auxiliando empresas, pesquisadores e sistemas inteligentes na tomada de decisões.


Atualmente, a análise emocional é aplicada em diversas áreas:

- Monitoramento de redes sociais
 - Atendimento ao cliente
- Sistemas de recomendação
 - Saúde mental
 - Segurança digital
- Marketing e reputação de marcas

Além disso, compreender emoções em textos é um dos problemas mais importantes e desafiadores do PLN moderno.

FUNDAMENTOS TEÓRICOS | TOKENIZAÇÃO

Como mostrado na imagem é o processo de dividir uma frase em palavras ou tokens individuais. É importante ressaltar que os tokens não são necessariamente apenas uma palavra e que caracteres especiais são removidos.



FUNDAMENTOS TEÓRICOS | TIPOS DE TOKENIZAÇÃO

- 1. Tokenização de Palavras:** Divide o texto em palavras individuais. Abordagem eficaz para idiomas com limites claros de palavras.
- 2. Tokenização de Caracteres:** O texto é segmentado em caracteres individuais. Abordagem útil para idiomas que não tem limites claros de palavras ou tarefas que exigem análise granular.
- 3. Tokenização de Subpalavras:** Esse método divide o texto em unidades que podem ser maiores que um único caractere, mas menor que uma palavra. Abordagem útil para idiomas que formam significado combinando unidades menores ou ao lidar com palavras fora do vocabulário em tarefas PLN.

FUNDAMENTOS TEÓRICOS | STOPWORDS

Técnica que faz a remoção de ruídos do texto que são menos evidentes que pontuações, como os conectivos “que”, “o”, “a”, “de”, entre outros. Quase todos os textos possuem conectivos e palavras comuns que não são significativas para nosso modelo.

Sample text with Stop Words	Without Stop Words
GeeksforGeeks – A Computer Science Portal for Geeks	GeeksforGeeks , Computer Science, Portal ,Geeks
Can listening be exhausting?	Listening, Exhausting
I like reading, so I read	Like, Reading, read


FUNDAMENTOS TEÓRICOS | STEMMING X LEMMATIZAÇÃO

O Stemming reduz uma palavra ao seu radical (stem) — a base comum das suas variações — sem considerar a gramática ou o significado linguístico. Ele remove sufixos e prefixos de forma mecânica, geralmente por regras heurísticas simples, como: retirar “-ando”, “-endo”, “-es”, “-mente” no português.

A Lemmatização reduz uma palavra à sua forma canônica (lema), levando em conta a gramática e o vocabulário. É o processo de encontrar o “dicionário” da palavra, usando análise morfossintática (POS tagging). Identifica a categoria gramatical (verbo, substantivo, adjetivo etc.); Consulta um vocabulário linguístico para encontrar o lema correto.

Stemming vs Lemmatization


change
changing
changes
changed
changer



chang

The diagram illustrates the stemming process. On the left, five words are listed vertically: 'change', 'changing', 'changes', 'changed', and 'changer'. Five blue arrows point from each of these words to a single word on the right, 'chang', which is colored blue. This represents the process of reducing different inflected forms of a word to their common root.

change
changing
changes
changed
changer



change

The diagram illustrates the lemmatization process. On the left, the same five words are listed vertically: 'change', 'changing', 'changes', 'changed', and 'changer'. Five blue arrows point from each of these words to a single word on the right, 'change', which is colored green. This represents the process of reducing different inflected forms of a word to their base or dictionary form.

FUNDAMENTOS TEÓRICOS | REPRESENTAÇÃO VETORIAL

Vetorização é um termo técnico para uma abordagem clássica de conversão de dados de entrada de seu formato bruto (ou seja, texto) em vetores de números reais, que é o formato suportado por modelos de aprendizado de máquina. Essa abordagem existe desde a invenção dos computadores, tem funcionado maravilhosamente bem em diversas áreas e agora é usada em PNL (Processamento de Linguagem Natural). Em aprendizado de máquina, a vetorização é uma etapa na extração de características. A ideia é obter características distintas do texto para que o modelo possa treiná-lo, convertendo o texto em vetores numéricos.

FUNDAMENTOS TEÓRICOS | BAG OF WORDS

Técnica mais simples existente, envolve três operações:

1. Tokenização
2. Criação de vocabulário
3. Criação vetorial

	the	red	dog	cat	eats	food
1. the red dog →	1	1	1	0	0	0
2. cat eats dog →	0	0	1	1	1	0
3. dog eats food →	0	0	1	0	1	1
4. red cat eats →	0	1	0	1	1	0

FUNDAMENTOS TEÓRICOS | TF-IDF

TF-IDF, ou ou Frequência do Termo – Frequência Inversa do Documento, é uma estatística numérica que visa refletir a importância de uma palavra em um documento. Embora seja outro método baseado em frequência, não é tão simplista quanto o Bag of Words.

$$\text{TF-IDF} = \text{TF} * \text{IDF}$$

TF



Frequency of a word
within the document

IDF



Frequency of a word
across the documents

FUNDAMENTOS TEÓRICOS | TF X IDF

TF, pode ser entendido como uma pontuação de frequência normalizada. É calculado através da seguinte fórmula:

$$\text{TF} = \frac{\text{Frequência de uma palavra no documento}}{\text{Número total de palavras no documento}}$$

IDF significa Frequência Inversa de Documentos, mas antes de falarmos sobre IDF, precisamos entender o que é DF – Frequência de Documentos. IDF, é o inverso da Frequência do Documento, e a pontuação final do IDF.

$$\text{IDF} = \log\left(\frac{\text{Número total de documentos}}{\text{Documentos contendo a palavra}}\right)$$


Introdução a LLM e ML para Análise de Sentimentos

LLM | COMPARAÇÃO COM TÉCNICAS SIMPLES/TRADICIONAIS

<i>Técnica</i>	<i>Base</i>	<i>Contexto</i>	<i>Precisão Emocional</i>	<i>Exemplo</i>
NLTK TextBlob	Léxica	Baixo	Média	“ótimo” = positivo
BERT	Pré-treinado em textos massivos	Alto	Alta	“ótimo” + contexto
GPT BLOOM Falcon	Linguagem completa	Muito Alto	Altíssima	Entende sarcasmo e nuances

LLM E ML | RELAÇÃO LLM E ML

Os LLMs são um subconjunto especializado do ML. Enquanto o ML é um campo vasto da inteligência artificial que abrange diversos algoritmos e modelos para aprender com dados, os LLMs focam especificamente na compreensão e geração de linguagem humana em larga escala.



Laboratório Prático

LABORATÓRIO PRÁTICO | ARQUITETURA BASE

1. **Pré-Processamento (PLN Tradicional):** Aqui acontecem as transformações rápidas e baratas. Porque as LLMs funcionam muito melhor quando o texto está limpo e padronizado.
2. **Análise Leve (PLN Clássico):** Aqui usamos técnicas rápidas para uma primeira classificação, sendo uma classificação inicial positiva, negativa e neutra.
3. **Análise Avançada (LLM):** Usamos modelos grandes para analisar apenas os textos difíceis e gerar a classificação.

Avaliações e boas práticas

AVALIAÇÃO | DESEMPENHO DO SISTEMA

Nós iremos possuir algumas métricas para conferir o desempenho de um sistema, sendo elas::

1. Acurácia: Taxa de acertos
2. Precisão: Confiabilidade das previsões positivas
3. Recall: Cobertura dos casos positivos
4. F1-Score: Balanço entre previsão e recall
5. Tempo médio de inferência: Rapidez do modelo

AVALIAÇÃO | CUSTOS E LIMITAÇÕES

Quando estamos falando sobre utilizar LLMs de grandes empresas como OpenAI, iremos possuir um custo considerável que pode custar de US\$ 0,03 a US\$ 0,12 por 1k de tokens, quando nos colocamos isso em uma ideia de que vamos possuir uma aplicação rodando 24/7 podemos ter um custo considerável ao utilizar LLMs de grandes empresas.

Porém quando pensamos em utilizar LLMs abertas entramos no viés das limitações, onde modelos como BERT ou BLOOM precisam de GPUs com pelo menos 8GB de VRAM e existem modelos como o BLOOM-176B que podem chegar a ocupar mais de 350GB no armazenamento do computador.

BOAS PRÁTICAS | BOAS PRÁTICAS

Podemos separar as boas práticas em 6 partes principais, cada um sendo uma área que iremos trabalhar, sendo elas:

1. Qualidade e Preparação de Dados
2. Monitoramento de Vieses
3. Documentação e Rastreabilidade
4. Otimização com prompt engineering
5. Engajamento com a comunidade
6. Ciclo de melhoria contínua

Discussão e Q&A

FICAMOS POR AQUI!
QUALQUER DÚVIDA:

(31) 99998-1418

bernardocmfgomes@gmail.com

@bernardocastro___
@bernardoodev

